TECHNICAL BRIEF IMPLEMENTASI CODEBASE

Rekayasa Arsitektur UDAO-LASFNet untuk Deteksi Objek Multimodal Aerial (RGB-IR) pada Antigravity AI Assistant

Peneliti Utama: Muhammad Ammar Allezandro Djosan

Target Platform: Antigravity AI / PyTorch Codebase

Baseline Model: LASFNet (~7.7M Params, ~26.6 GFLOPs)

Target Repository: UDAO-LASFNet (Branch: feature/udao-dfatm)

1. Konteks Penelitian & Spesifikasi Baseline LASFNet

Dokumen teknis ini dirancang sebagai petunjuk instruksional utama (*briefing manual*) untuk asisten pengkodean AI (Antigravity) dalam merekayasa arsitektur model **LASFNet** (Lightweight Attention-Guided Self-Modulation Feature Fusion Network) menjadi **UDAO-LASFNet**. Penelitian ini berfokus pada peningkatan performa deteksi objek multimodal RGB-Infrared pada citra drone aerial (*top-down view*).

Profil Komputasi Baseline LASFNet

Atribut Arsitektur	Spesifikasi Baseline LASFNet Asli
Backbone Network	Dual-Stream CSPDarknet53 (RGB Stream: Layer 0–4, IR Stream: Layer 5–9)
Multimodal Fusion Layer	ASFF (Attention-Guided Self-Modulation Fusion) di Layer 10 / P3 (stride 8)
Neck Network & Feature Pyramids	FATM (Feature Attention Transformation Module) terintegrasi FPN + PANet
Parameter & FLOPs Ceiling	Total Parameter: ~7.70M | Beban Komputasi: ~26.6 GFLOPs

2. Problematika Empiris & Gap Analisis Dataset Aerial

Meskipun LASFNet sangat unggul pada dataset CCTV jalanan seperti LLVIP, pengujian pada dataset drone aerial (**DroneVehicle** dan **VTUAV-det**) mengungkapkan empat keterbatasan empiris utama yang menjadi fokus rekayasa arsitektur kita:

1. **Spatial Misalignment (Paralaks & Getaran Drone):** Pada dataset VTUAV-det, pasangan citra RGB dan Infrared mengalami pergeseran spasial rata-rata sebesar 10.99 piksel. Penjumlahan langsung (element-wise addition) pada modul ASFF tanpa mekanisme alignment menyebabkan fusi fitur tercemar oleh background noise.
2. **Keterbatasan 1D Positional Attention (PAM):** Sub-modul PAM pada ASFF bawaan menggunakan 1D Average Pooling lurus sepanjang sumbu H dan V. Pada citra drone sudut pandang atas (top-down view), kendaraan berorientasi miring bebas (360° rotated objects). Pooling 1D lurus memotong dan membuang informasi geometri tepi objek diagonal.
3. **Ambiguitas Kelas Spesifik (van vs car):** Pada dataset DroneVehicle, akurasi mAP50 kelas car mencapai 95.9%, namun kelas van anjlok di angka 70.5%. Dari sudut atas, bentuk atap van dan car terproyeksi sangat mirip secara 2D. Model membutuhkan ekstraksi kontur gradien spasial yang lebih diskriminatif.

4. Degradasis Sinyal Objek Mikro (Tiny Targets): Proses downsampling bertahap pada jaringan dalam menghapus sinyal pejalan kaki/objek mikro pada VTUAV-det, sehingga membutuhkan anchoring interaksi fusi yang tetap terkunci pada resolusi tinggi P3 (stride 8).

3. Detil Spesifikasi Rekayasa Arsitektur UDAO-LASFNet

A. Modul 1: UDAO-ASFF (Unified Deformable Alignment & Orientation ASFF)

Modul **UDAO-ASFF** dipasang pada Layer 10 / P3 (stride 8) menggantikan modul ASFF standar. Modul ini menggabungkan koreksi misalignment dan sampling berorientasi miring dalam satu kali langkah Deformable Convolution (DCN) berpanduan cross-modal:

- **Infrared Spatial Reference Anchor:** Fitur IR (P_IR) dijadikan acuan lokasi utama karena sinyal thermal stabil dari dark noise pada kondisi malam/mewah.
- **Cross-Modal Offset Generator:** Memprediksi peta pergeseran spasial dari fitur IR menggunakan konvolusi depthwise 3x3 dan aktivasi Tanh: $\Delta P_{rgb} = \tanh(DWConv_{3x3}(P_{IR}))$.
- **Single-Step Alignment & 360° Re-sampling:** Menerapkan DCN berpanduan ΔP_{rgb} pada fitur RGB (P_{RGB}). Operasi ini secara serentak menggeser koordinat piksel RGB yang misaligned ke IR sekaligus mere-sample kisi konvolusi agar fleksibel mengikuti sudut miring kendaraan (360°).
- **Feature Modulation Block (FMB):** Hasil DCN diekstrak dan dilebur bersama fitur IR menggunakan gating self-modulation bawaan.

B. Modul 2: D-FATM (Discriminative FATM) + Dual-Strategy Contour

Modul **D-FATM** dipasang pada bagian neck (PANet Layer 24) untuk mempertajam garis tepi dan pilar kendaraan guna mengatasi ambiguitas kelas van vs car:

- **In-Model Depthwise Sobel/Laplacian Filter (Inference & Training):** Disisipkan di dalam FATM menggunakan 3x3 depthwise separable Sobel/Laplacian conv + contrastive channel attention untuk menangkap gradien kontur fisik dengan penambahan parameter mikroskopis (< 0.05M).
- **Auxiliary Boundary Loss / BAB (Training-Only):** Menambahkan supervisi garis tepi (Laplacian edge target) dari gambar input sebagai auxiliary loss pada fungsi loss (utils/loss.py). Cabang ini dilepas total saat inference, menghasilkan 0 ms latensi komputasi ekstra.

4. Blueprint Implementasi Codebase PyTorch untuk Antigravity

Petunjuk untuk Antigravity: Lakukan modifikasi kode secara modular pada branch feature/udao-dfatm. Jangan menghapus class bawaan (ASFF dan FATM), melainkan buat class baru UDAO_ASFF dan D_FATM di file terkait agar baseline asli tetap dapat dievaluasi secara berdampingan.

File Target Codebase	Komponen / Class Baru	Tugas & Instruksi Pengkodean
`models/modules.py`	**CrossModalOffsetGenerator & UDAO_ASFF**	Gantikan 1D pooling PAM dengan DCN (torchvision.ops.deform_conv2d). Hitung offset spasial dari P_IR untuk mere-sample P_RGB.

File Target Codebase	Komponen / Class Baru	Tugas & Instruksi Pengkodean
`models/neck.py`	**D_FATM**	Sisipkan filter gradien Sobel/Laplacian 3x3 depthwise separable conv pada modul FATM untuk ekstraksi kontur batas kendaraan.
`models/udao_lasfnet.yaml`	**Arsitektur Network Config**	Buat file YAML baru yang memanggil UDAO_ASFF pada Layer 10 dan D_FATM pada neck Layer 24.
`utils/loss.py`	**AuxiliaryBoundaryLoss**	Implementasikan Auxiliary Boundary Loss berbasis Binary Cross-Entropy antara edge map input dan intermediate feature D_FATM (hanya aktif saat self.training == True).

5. Batasan Komputasi & Target Hipotesis Performa

Pengembangan UDAO-LASFNet wajib mematuhi batasan komputasi ultra-ringan (*lightweight budget ceiling*) serta diproyeksikan mencapai peningkatan performa berikut:

Metrik Evaluasi	Baseline LASFNet	Target UDAO-LASFNet
DroneVehicle Overall mAP50	85.50%	**87.50% – 89.00% (+2.0% s/d +3.5%)**
DroneVehicle Class 'van' mAP50	70.50%	**76.00% – 78.00% (+5.5% s/d +7.5%)**
VTUAV-det mAP50-95 (Misaligned)	37.80%	**41.30% – 43.80% (+3.5% s/d +6.0%)**

Batas Maksimal Komputasi: Total Parameter tetap di bawah **8.0M** (proyeksi ~7.80M), FLOPs stabil di **~26.6 GFLOPs**, dan latensi inferensi batch-1 tetap di kisaran **~49.8 ms**.

6. Urutan Eksekusi & Validasi Kode

Langkah 1: Setup Environment & Profiling Baseline — Jalankan thop / torchinfo pada lasfnet.yaml di branch main untuk mengunci angka parameter baseline (~7.70M) dan GFLOPs (~26.6).

Langkah 2: Penulisan Modul UDAO_ASFF & D_FATM — Implementasikan class UDAO_ASFF dan D_FATM di branch feature/udao-dfatm.

Langkah 3: Dry Run & Profiling UDAO-LASFNet — Jalankan profiler pada udao_lasfnet.yaml untuk memastikan total parameter tetap < 8.0M dan tensor output berukuran pas (batch_size, num_classes, H, W).

Langkah 4: Sanity Check Forward Pass — Lakukan single batch forward pass (1 pasang RGB-IR image) untuk memverifikasi tidak ada CUDA memory error atau dimension mismatch.

Langkah 5: Training & Evaluasi mAP — Jalankan skrip train.py pada dataset DroneVehicle dan VTUAV-det, dilanjutkan evaluasi val.py.